Programm zum Vergleich verschiedener Ansätze zur Lösung nicht effizient lösbarer Probleme anhand des Brettspiels Dame

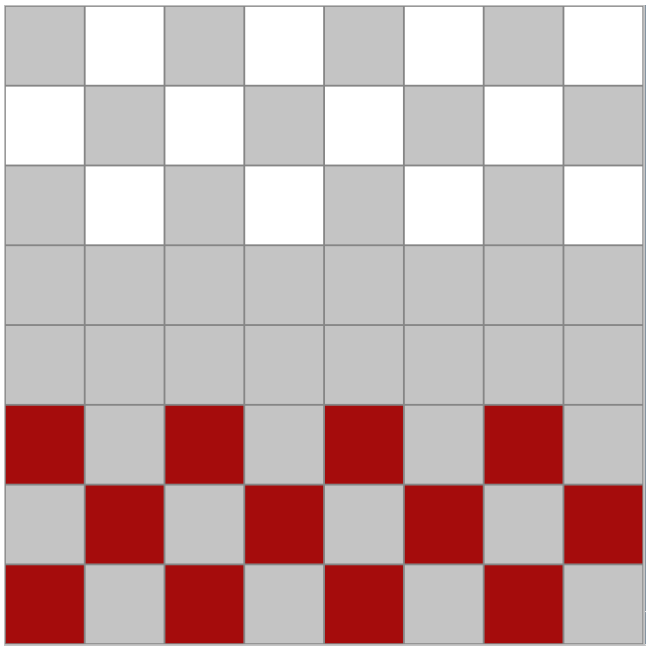

Jugend Forscht Arbeit

betreut von

Herr Frerkes

am

Steinhagener Gymnasium
Stufe Q2

14.01.2018

von

Marco Adamczyk Till Brinkmann Can Ward

Download des Programms und der Dokumentation:
https://github.com/Gametypi/Checkers-Simulation

Abstract

In unserer Facharbeit beschäftigen wir uns mit den verschiedenen Methoden einen Gegenspieler für das Brettspiel Dame zu programmieren. Wir haben grundsätzlich zwischen zwei unterschiedlichen Ansätzen differenziert.
Zum einen gibt es die konventionellen Lösungsalgorithmen von Nullsummenspielen wie beispielsweise der MiniMax-Algorithmus. Diesen haben wir auf verschiedene Weisen implementiert. Einmal ohne Verbesserungen, mit Multithreading und mit Alpha-Beta Suche und diese daraufhin auch verglichen und bewertet.
Zum anderen haben wir uns Lösungen durch maschinelles Lernen angeschaut sowohl ein evolutionsbasiertes Neuronales Netzwerk implementiert als auch den Backpropagation Algorithmus eingesetzt.
Um jedoch diese Ansätze auszuprobieren und letztendlich auch auswerten zu können, benötigen wir ein Programm, welches uns ermöglicht all dies zu testen. Deshalb haben wir ein Programm mit einer Benutzeroberfläche entwickelt, mit welchem wir die verschiedenen Algorithmen gegeneinander spielen lassen können. Besonders haben wir darauf geachtet, dass es modular bleibt und man jederzeit Algorithmen hinzufügen und entfernen kann, um auch anderen Personen ,die daran interessiert sind, zu ermöglichen eigene Algorithmen zu schreiben und diese zum Programm hinzuzufügen ohne dieses verändern zu müssen. Das ist einer der Gründe warum wir den Quellcode als auch die Dokumentation vollständig auf Englisch geschrieben haben.
Der Vergleich dieser Ansätze fand unter verschieden Aspekten statt, damit die Vor- und Nachteile vollständig dargestellt werden können.
Deshalb müssen die Ergebnisse auch häufig differenziert betrachtet werden, denn es kann nicht gesagt werden, dass ein Ansatz allgemein besser ist, sondern nur unter einzelnen Gesichtspunkten mehr Vorteile besitzt. Was besser ist entscheidet sich dadurch, welchen Nutzen dieses Programm haben soll und was dem Nutzer besonders wichtig ist.
Diese Ergebnisse können nicht nur auf das Damespiel bezogen werden und lassen auf die grundlegenden Unterschiede zwischen Algorithmen und Neuronalen Netzen in verschiedenen Kontexten schließen.

Inhaltsverzeichnis

1. Einleitung 2

2. Checkers Simulation 2.0 3

2.1 Warum Dame? 3

2.2 Zielsetzung/Anforderungen 4

2.3 Umsetzung/Implementation

2.4 Verbesserungen/Zusammenfassung 5

3. MinMax 6

3.1 Konzept des Algorithmus 6

3.2 Variationen 9

3.2.1 Alpha-Beta Suche

3.2.2 Multithreading

3.3 Effizienzvergleich 10

3.4 Zusammenfassung

4. Das Neuronale Netzwerk 11

4.1 Einführung 11

4.2 Umsetzung 12

4.3 Lernprozess/Optimierung 14

4.3.1 Evolutionärer Ansatz

3.2.1.1 Gegen sich selber

3.2.1.2 Genen den MiniMax

4.3.2 Backpropagation 15

5. Alternative Ansätze 16

5.1 Datenbank-basierter Spieler 16

5.2 Zufallsbasierter Spieler

6. Vergleich/Fazit 17

7. Quellenverzeichnis 18

8. Anhang 19

1. Einleitung

Schon immer war es eines der Ziele der Menschheit Problemstellungen so effizient wie möglich zu lösen. Denn gerade durch die Lösung vieler Probleme konnte sich die Menschheit im Lauf der Geschichte schnell weiterentwickeln. Zunächst mit den bloßen Verstand, danach mit immer komplexeren Hilfsmitteln. Mit Rechenmaschinen wie zum Beispiel der Pascaline[1] wurden bereits im Mittelalter die Grundlagen für das Lösen komplizierter Aufgaben gelegt [1,2,3,4]. Es wurde schnell erkannt, dass es Aufgaben und Problemstellungen gibt, die das Gehirn nicht so schnell bewältigen kann oder es sich einfach nicht lohnt diese zu bewältigen, da der Mensch sich in der Zwischenzeit wichtigeren Dingen zuwenden kann.
In der heutigen Zeit hat sich neben den anderen Naturwissenschaften besonders die Informatik dieser Menschheitsaufgabe angenommen und ist daher immer auf der Suche nach besseren Möglichkeiten Probleme zu lösen.
Neue Computersysteme und besonders Supercomputer sind in der Lage zur Zeit bis zu 93,0 PFLOPS[2] zu berechnen und diese Rechenleistung steigt immer noch exponentiell (Moorsches Gesetz). Jedoch sind manche Probleme, trotz dieser Zunahme, mit konventionellen Algorithmen nicht lösbar, wie beispielsweise das Traveling-Salesman Problem[3] eindeutig zeigt [5].
Doch gerade diese stark zunehmende Rechenleistung lässt nämlich zunehmend auch neue Lösungsmöglichkeiten zu, wie beispielsweise die des maschinellen Lernens. Deshalb ist es immer wichtig auf der Suche nach neuen Ansätzen zu sein und diese unter diversen Aspekten mit den bewährten Verfahren zu vergleichen. Doch welche Methoden der Problemlösung sind die effektivsten, genauesten, zeitsparendsten, passendsten und zukunftssichersten für den jeweiligen Zweck?
Genau dies wollen wir in dieser Facharbeit annähernd und ansatzweise am Beispiel des Brettspiels Dame erläutern. Durch diese Bedeutung und Aktualität des Themas haben wir uns entschieden selbständig den Vergleich zu schaffen zwischen konventionellen Algorithmen und einem Neuronalen Netzwerk, dass den Ansatz des maschinellen Lernens verfolgt.
Zunächst gehen wir auf das Problem ein, dass wir mithilfe dieser Methoden lösen wollen.
Nach dieser theoretischen Einführung wollen wir auf die Umsetzung dieses Projektes eingehen, indem wir zunächst das Augenmerk auf die Grundlage legen, die uns den Vergleich erst ermöglicht hat. Es ist neben den Lösungsansätzen auch ein essenzieller Bestandteil dieses Projekts, der uns viel Zeit in der Entwicklung gekostet hat.
Im nächsten Abschnitt fokussieren wir uns auf die einzelnen Lösungsansätze und versuchen diese in der Tiefe auszuarbeiten und zu erklären. Besonders haben wir versucht unsere Implementierung der jeweiligen Methode zu präsentieren und zu erklären. Außerdem gehen wir noch auf andere Methoden der Problemlösung ein, die wir aber aus diversen Gründen nicht in unser Programm aufgenommen haben, um dem Leser einen besseren Überblick zu verschaffen.
Als letzten Schritt vergleichen wir diese zuvor erklärten Wege der Problemlösung an unserem Beispiel und geben ein differenziertes Fazit wieder, indem wir sie unter unterschiedlichen Aspekten
vergleichen. Des Weiteren versuchen wir grundlegend in jedem größeren Abschnitt dieser Arbeit unsere Herangehensweise zu reflektieren.

1 Eine um 1645 entwickelte Rechenmaschine vom französischen Mathematiker Blaise Pascal. Sie basiert auf einem mechanischen Konstrukt aus Zahnrädern und Sperrklinken. Sie wurde ursprünlich daür einwickelt Pascals Vater die Arbeit als Steuerbeamter zu erleichtern.

2 Steht für 93 *10^{15} Floating Point Operations Per Second. So schnell rechnet der chinesische Supercomputer Sunway-TaihuLight[6,7].

3 Ein Problem der Mathematik und Informatik, dass nicht effizient lösbar ist, also einen annähernd exponentiellen Aufwand aufweißt.

2. Checkers Simulation 2.0

2.1 Warum Dame?

In diesem Teil wollen wir erklären warum wir das Brettspiel Dame als Grundlage für unser Projekt gewählt haben. Zunächst wollten wir die Anforderungen an unser Problem definieren:

- Es war uns wichtig, dass das Problem weit verbreitet ist und viele Leute es kennen. Andere Personen können sich somit einfacher in unser Projekt rein arbeiten.
- Ein weiterer nicht zu vernachlässigender Aspekt ist der Programmieraufwand.
- Zudem sollte es vollständig berechenbar sein, da so garantiert wird, dass es theoretisch sowohl vom Algorithmus, als auch neuronalen Netzwerk gelöst werden kann.
- Es sollte nicht effizient lösbar sein, also einen nahezu exponentiellen Aufwand besitzen.

Besonders das Brettspiel Dame erfüllt diese Voraussetzungen, denn es ist ein weltweit populäres Spiel, welches mit ähnlichen Regeln auf der ganzen Welt gespielt wird. Dadurch ist es auch wahrscheinlich, dass den Lesern das Verstehen der Facharbeit leichter fällt. Aber auch wenn die Regeln nicht beherrscht werden, ist das Spiel leicht zu erlernen, da es nur eine geringe Anzahl Spielmechaniken gibt. [Regeln im Anhang]
Des Weiteren lässt sich das Spiel durch die geringe Komplexität Regeln und Mechaniken mit einem relativ geringen Aufwand implementieren.
Es ist ein Zwei-Personen-Nullsummenspiel, da es entweder Sieg, Niederlage oder Unentschieden geben kann. Außerdem gibt bei diesem Spiel keinen Zufall, es ist ein Spiel mit perfekter Information[4] und ist nicht unendlich lang, da nach einer gewissen Anzahl von Zügen ein Unentschieden erzwungen wird.
Somit besitzt es ein eindeutiges Spielergebnis, wodurch sich vermuten lässt, dass das Spiel auch berechenbar ist. Dies wurde auch durch den Algorithmus Chinook bewiesen, welcher nach mehreren Jahren das Spiel komplett berechnete. Daher muss es auch eine endliche Anzahl an Spielsituationen geben. Diese kann durch Kombinatorik berechnet werden:

$$\sum_{r_{normal}=1}^{12} \sum_{r_{dame}=0}^{r_{normal}} \sum_{w_{normal}=1}^{12} \sum_{w_{dame}=0}^{w_{normal}} \frac{32!}{(r_{normal}-r_{dame})!\cdot r_{dame}!\cdot(w_{normal}-w_{dame})!\cdot w_{dame}!\cdot(32-(w_{normal}+r_{normal}))!}$$

r_normal: normale rote Figuren
r_dame: rote Damen
w_normal: normale weiße Figuren
w_dame: weiße Damen

Man kann hier das Prinzip der Berechnung für Permutation mit Wiederholung anwenden. Die Anzahl der besetzbaren Felder bei einem standard Dame 8*8 Feld liegt bei 32, somit gibt es auch 32 Möglichkeiten ein Objekt auf dem Spielfeld anzuordnen. Man muss dabei zwischen den unterschiedlichen Figurentypen, die in unserer Formel durch die jeweilige Variable repräsentiert werden, und den leeren Felder unterscheiden. Letzteres lässt sich aus der Differenz der besetzten Felder und der Anzahl der Figuren bestimmen.
Des Weiteren muss berücksichtigt werden, dass diese Berechnung mit jeder Kombinationen der Anzahl der normalen Figuren und Damen berechnet werden muss, da sich durch die Veränderung immer neue Anordnungen ergeben. Dies wurde durch die Summenzeichen umgesetzt.
Das Ergebnis dieser Rechnung liegt bei 6.011e+20.
Insgesamt wird hier deutlich, dass dieses Spiel trotz der relativ simplen Mechanik durch die hohe Anzahl an möglichen Spielfeldsituationen einen sehr hohen Berechnungsaufwand aufweist und sich somit die Frage stellt, ob neuronale Netze bei Nullsummenspielen eine Alternative zu konventionelle Algorithmen darstellen können.

4 Dies bedeutet, dass jeder Spieler zu jeder Zeit das Wissen über das passierte Spielgeschehen hat.

2.2 Zielsetzung/Anforderungen (Was soll es können):

Unser Programm, welches wir als Grundlage für den Vergleich genutzt haben, wurde von uns Checkers Simulation 2.0 genannt.
Es ist eine mit Java programmierte Anwendung, die bestimmte Dinge erfüllen sollte, damit wir die von uns programmierten Algorithmen darauf testen konnten.
Es besitzt eine grafische Oberfläche, mit einem Spielfeld, einer Eingabe und Ausgabekonsole und weiteren Optionen. Es ist möglich Spiele sowohl gegen Computergegner, die dem Programm zu Verfügung stehen, als auch gegen einen anderen menschlichen Spieler zu spielen. Dies und andere Optionen kann man dann beim Start eines neuen Spiels auswählen. Man kann auch noch beispielsweise die Anzahl der Runden bestimmen, die gespielt werden oder ob das Spiel ausgewertet werden soll. Die Auswertung speichert alle wichtigen Werte in Dateien, sodass es im Nachhinein ausgewertet werden kann.
Auf der eigenen Konsole werden während und nach dem Spiel alle wichtigen Ereignisse, Fehler und Warnungen ausgegeben. Durch die Eingabe kann man auch Zugriff auch die Algorithmen kriegen.
Zudem gibt es die Möglichkeit ein anpassbares neuronales Netz zu trainieren. [Bedienungsanleitung im Anhang]

Das Programm wurde von uns mit der Programmiersprache Java entwickelt, da uns eine objektorientierte Programmierung wichtig war. Diese hat es uns ermöglicht das Programm sinnvoll zu strukturieren und damit zugänglicher für andere zu machen. Es ist auch einfacher Teile des Quellcodes wiederzuverwenden und Fehler zu beheben. Zudem gibt es noch weitere Vorteile, die unsere Entscheidung maßgeblich beeinflusst haben. Java ist eine weit verbreitete Programmiersprache, die besonders auf Portabilität und Parallelisierbarkeit ausgelegt ist.
Natürlich müssen auch die schwächen kurz erwähnt werden, denn Java ist in vielen Bereichen nicht so effizient wie andere Programmiersprachen. Jedoch, unter Berücksichtigung der anderen Aspekte, lässt sich sagen, dass Java für unsere Ansprüche eine durchaus berechtigte Wahl gewesen ist.
Die Entwicklungsumgebung, die wir gewählt haben, ist Eclipse. Diese IDE hat sich als sehr zuverlässig erwiesen und bietet einige Vorteile, wie zum Beispiel eine größere Anzahl an Funktionen, die das Programmieren vereinfacht haben und die besseren Debugmöglichkeiten.
Außerdem haben wir als Sprache für den Quellcode und die Dokumentation Englisch verwendet. Englisch ist eine weltweit verbreitete Sprache, die mittlerweile in der Arbeitswelt aufgrund der fortschreitenden Globalisierung als der Grundlage der Kommunikation gilt. Unser Programm wird dadurch nicht nur auf den deutschsprachigen Raum begrenzt, sondern für jeden zugänglich sein, der sich damit befassen möchte.

2.3 Umsetzung/Implementation

Die diversen Klassen des Programms habe wir in verschiedene Pakete zusammengefasst um sie inhaltlich voneinander abzugrenzen.
Zum einen gibt es das Paket checkers, welches alle Klassen zusammenfasst die direkt etwas mit dem Spiel und dessen Ablauf zu tun haben. Dass wäre die Figure, sie repräsentiert eine Damefigur mit Positions-, Typ-, und Farbvariablen[5]. Diese Figuren werden in einer Klasse namens Playfield zusammengefasst. Sie bietet mehrere Methoden um die Situation auf dem Spielfeld zu erfassen, zum Beispiel `isOccupied(x, y)` oder `getFigureQuantity(FigureColor)`, aber auch zu verändern wie `executeMove(Move).`
Jeder Zug in einem Spiel wird auch als eigenes Objekt vom Typ Move behandelt. Move enthält alle nötigen Variablen um einen Zug eindeutig zu identifizieren und einige statische Methoden die eine Spielfeldsituation analysieren und eine Liste aller möglichen Züge, nur Schlagzüge oder nur Schritte zurückgeben.
Als vorletztes findet sich die GameLogic. Sie koordiniert ein gesamtes Spiel das auch aus mehreren Einzelrunden bestehen kann. Dafür erhält sie in ihrer `startGame()` Methode die zwei Spieler, den (optionalen) Spielnamen, die Anzahl der Runden, die Geschwindigkeit für nicht menschliche Spieler, einen Wahrheitswert, der aussagt ob das Spiel angezeigt werden soll[6] und noch einen der anzeigt ob man auf dem gerade angezeigten Spielfeld weiterspielen oder

5 Durch die Farbe kann erkannt werden, zu welchem Spieler die Figur gehört.
6 Nützlich wenn man statistische Ergebnisse aus dem Spiel von zwei nicht menschlichen Spielern bekommen möchte. Das Spiel läuft ohne Anzeige nochmal ein bisschen schneller.

ein neues nutzen möchte. Eine weitere Aufgabe der GameLogic ist die Zugvalidation mit der Methode `testMove(Move, Playfield)`.
Einer der kürzesten, aber definitiv wichtigsten Klassen des Projekts ist das Interface Player.

public interface Player

`public:`
`void prepare()`
`void requestMove()`
`String getName()`
`boolean acceptDraw()`
`void saveInformation()`

Abbildung 2.1: Methoden des Player Interfaces

Dieses Interface muss von jedem Algorithmus und jeder sonstigen Klasse die ein Spiel in unserem Programm spielen möchte implementiert werden. Alle nötigen Informationen können nur über dieses Interface kommuniziert werden. Dadurch erreichen wir eine größtmögliche Modularität und können Spieler beim Start des Programms dynamisch laden.
Das nächste Paket heißt evaluation. Es ist eine Sammlung zweier Klassen die genutzt werden um ein Spiel zu dokumentieren und eine Vielzahl von Informationen zu speichern, die hilfreich sind um Spielstärke und Schnelligkeit der einzelnen Spieler zu bewerten. Zusätzlich erhält jeder Spieler durch die `saveInformation()` Methode nach jeder Runde die Möglichkeit eigene Informationen zu speichern.
Das Paket gui enthält alle Klassen die etwas mit der graphischen Oberfläche des Programms zu tun haben.
Am wichtigsten ist hier GUI. Das ist sowohl die Hauptklasse unseres Programms als auch das Hauptfenster.
Im Konstruktor werden alle graphischen Komponenten initialisiert die das Projekt benötigt. Die GUI hat Zugriff auf die meisten Klassen, weil sie auch Einstellungen weitergibt. Die weiteren Klassen sind größtenteils Panele oder Fenster, die bestimmte Einstellungen oder in sich geschlossene graphische Komponenten enthalten. Das Playfieldpanel implementiert zusätzlich noch das Interface Player um dem Nutzer das Spielen zu ermöglichen.
Als Nächstes kommt das Paket network. Es enthält die Klassen, die alle Netzwerkaktivitäten des Programms koordinieren.
Zuletzt gibt es noch zwei Pakete, datastructs und utilities, die Klassen und Methoden enthalten die an vielen Stellen genutzt werden und deswegen als eigenes Paket in das Projekt eingebracht wurden.

2.4 Verbesserungen/Zusammenfassung

Insgesamt ist dieses Programm ein vielseitiges und starkes Tool zum Auswerten von Algorithmen. Es bietet einige Funktionen und lässt sich relativ intuitiv bedienen. Eine der Schwächen ist, dass die Struktur manchmal nicht optimal ist und dass es dadurch etwas unübersichtlicher ist. Um dem entgegenzuwirken, könnte man einige Dinge noch in unterschiedliche Methoden und Klassen auslagern. Außerdem haben wir manche Funktionen, die wir uns zu Beginn vorgenommen haben, nicht implementieren können.

3. MiniMax Algorithmus

3.1 Konzept

Der MiniMax Algorithmus[7] ist ein informatischer Ansatz zur Lösung von Zwei-Spieler-Nullsummenspielen. Er basiert auf dem MiniMax Prinzip in dem zur Voraussage eines Gewinns immer der schlechteste mögliche Weg genommen wird (daher auch pessimistisches Prinzip). Dadurch lässt sich immer ein absolut sicher erreichbares Ergebnis voraussagen [8].
In unserem Fall bedeutet das also, dass davon ausgegangen wird das der Gegner immer den bestmöglichen Zug macht (das wäre der schlechteste Fall).
Es muss also versucht werden, mit dem gewählten Zug die maximale Zugqualität des Gegners zu minimieren und die minimale eigene Qualität zu maximieren (daher auch der Name). Die eben genannte Qualität eines Zuges wird im Algorithmus durch eine Bewertungsfunktion errechnet. Diese Bewertungsfunktion gibt hohe Werte für Züge die gut für den Spieler sind und niedrige, meist negative Werte für Züge von denen der Gegner profitiert. Eine optimale Bewertungsfunktion würde also den Wert 1 für das Gewinnen des Spiels und -1 für das Verlieren annehmen. Ein Gleichstand würde mit 0 bewertet werden.

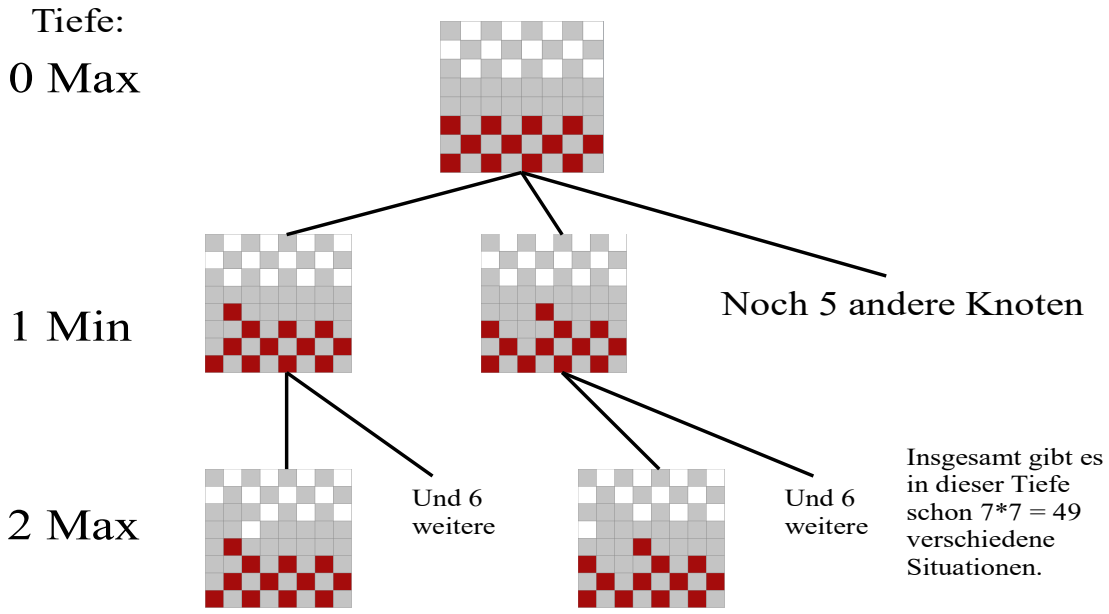

Abbildung 3.1: Modell eines MiniMax Suchbaums mit Tiefe 3 ausgehend von der Dame Startposition

In obenstehender Abbildung sehen wir die Arbeitsweise des MiniMax mit einer festen Tiefe. In Tiefe 0 wird für jeden Zug, der auf dem momentanen Spielfeld möglich ist, ein neuer Ast erstellt. Jeder dieser Äste erstellt neue Zweige nach dem gleichen Prinzip, allerdings wird hier die ursprüngliche Spielfeldsituation mit dem ausgeführten Zug des Elternknotens als Ursprung genommen. Der aufgebaute Suchbaum wird post-order[8] traversiert.
Die Evaluation wird nur in den Blättern[9] durchgeführt, das Ergebnis wird dabei zum Elternknoten hochpropagiert. Dieser vergleicht alle Ergebnisse der Kindknoten und bestimmt, je nachdem ob es eine Min-/ oder Max-Ebene ist den größten oder kleinsten Wert. Dieser Wert wird wiederum an die Elternknoten weitergegeben bis alle Werte bei der Wurzel angelangt sind. Die Wurzel führt dann die Aktion aus die mit dem Ast assoziiert wird, der den besten Wert zurückgegeben hat.
Das ermöglicht dem MiniMax je nach Suchtiefe mehrere Züge vorauszuberechnen und so einen besseren Überblick über Langzeitfolgen der Aktion zu bekommen [9].

7 Ein Algorithmus kann als eine Handlungsvorschrift beschrieben werden, welche durch eine systematische und definierbare Vorgehensweise eine Problemstellung lösen kann.
8 Die post-order Traversierung beschreibt in der Informatik eine Methode der Suchbaumtraversierung. Hierbei wird immer zuerst der linkeste Kindknoten, danach die rechteren Kindknoten und zum Schluss die Wurzel selbst abgearbeitet.
9 Ein Knoten, der keine Kindknoten besitzt wird als Blatt bezeichnet.

Wie in Abbildung 3.1 zu sehen ist, wird die Anzahl der zu berechnenden Situationen pro Tiefe exponentiell größer. Linear dazu steigt auch der Rechenaufwand und somit auch die Rechenzeit. Dieses lässt sich aus den folgenden, empirisch mit der Auswertungsfunktion der Checkers Simulation 2.0 erhobenen Ergebnissen schlussfolgern. Dafür wurde der Durchschnittswert aus 100 Spielen ermittelt.

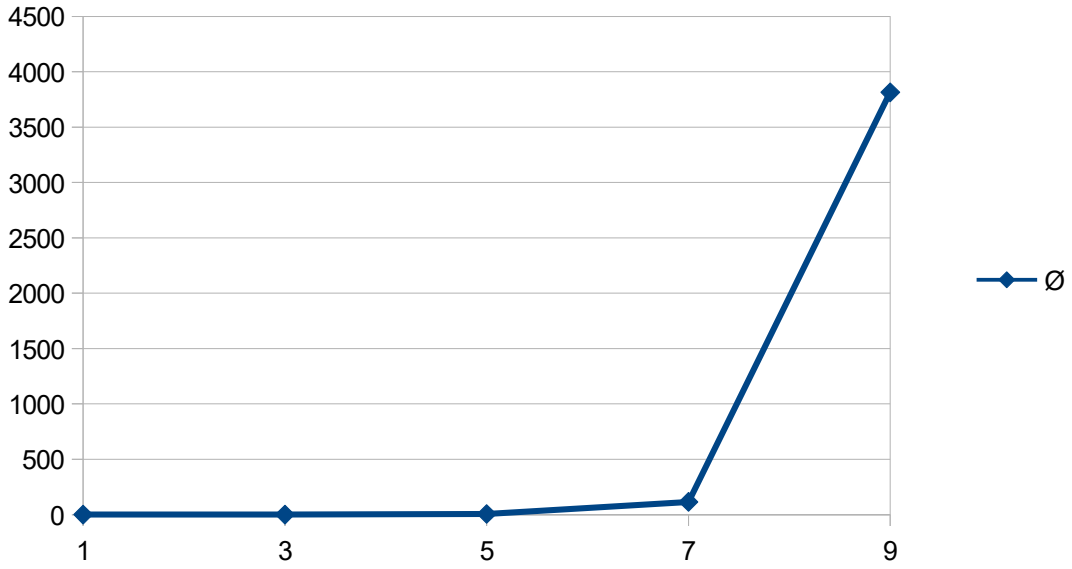

Abbildung 3.2: Durchschnittliche Zugzeiten des MiniMax in Millisekunden mit verschiedenen Maximaltiefen

Ein durchschnittliches ausgewogenes Damespiel besteht aus etwa 50 bis 70 Zügen. Um eine sichere Gewinnchance zu berechnen müsste man diesen Suchbaum im schlimmsten Fall also bis zu einer Tiefe von 70 generieren. Es ist also aufwendig den Baum bis zu einer Situation aufzubauen in der sich eindeutig bestimmen lässt, ob das Spiel gewonnen wird oder nicht. Bei den meisten Problemen kann eine ideale Bewertungsfunktion also nicht verwendet werden da der Zeit-/ oder Rechenaufwand einfach zu hoch wäre.
Daher haben wir eine Bewertungsfunktion entwickelt, die andere Parameter zur Bewertung nutzt:

$$Wert_{Blatt} = (Figurenanzahl_{Tiefe\,0\,;\,Gegner} - Figurenanzahl_{TiefeMax\,;\,Gegner}) + \square$$
$$(Figurenanzahl_{TiefeMax\,;\,Spieler} - Figurenanzahl_{Tiefe\,0\,;\,Spieler})$$

Diese Funktion berechnet, wie viele Figuren des Gegners geschlagen wurden und wie viele Figuren von einem selbst. Je mehr Figuren des Gegners geschlagen wurden, desto höher ist die Bewertung.
Für jede eigene geschlagene Figur wird allerdings ein Punkt abgezogen. Dadurch lässt sich, ohne die Endsituation zu kennen, eine zuverlässige Gewinnprognose erstellen.
Unsere Implementation dieses Algorithmus besteht aus 3 Klassen. Die erste ist der MiniMaxPlayer selbst. Diese Klasse implementiert das Player Interface und dient damit hauptsächlich als die Schnittstelle zum restlichen Programm und als Wurzel des Suchbaums.
Die zweite Klasse ist der MiniMaxTask. Sie implementiert den Kern der Berechnung und repräsentiert einen Knoten des Suchbaums. Um nötige Informationen für Zugbewertung und Programmflusssteuerung, hauptsächlich die maximale Tiefe um das Ende des Baumes zu bestimmen und die Figurenanzahlen die in der Bewertungsformel genutzt werden, für jeden MiniMaxTask verfügbar zu machen, gibt es noch einen MiniMaxManager der diese Daten speichert.

MiniMaxPlayer	**MiniMaxTask**	**MiniMaxManager**
bestMove bestValue prepare() requestMove()	value move playfield compute() evaluateMove()	playerColor enemyColor maxDepth updateFigureCounts() getFigureQuantity()

Abbildung 3.3: Wichtigste Methoden und Variablen der MiniMax Klassen

Die wichtigsten Variablen im MiniMaxPlayer sind, neben allem was für den Player gebraucht wird wie Konsole und Gamelogic, der beste Move, welcher am Ende der Berechnung auf dem Spielfeld ausgeführt wird und die dazugehörige beste Bewertung. Fast alle Methoden sind vom Player Interface implementiert, die wichtigsten hier sind prepare(), welche einen für das startende Spiel passenden MiniMaxManager mit den richtigen Spielerfarben erstellt und requestMove(). Wenn diese Methode aufgerufen wird, startet eine neue MiniMax Berechnung. Dafür wird zuerst eine Liste aller möglichen Züge erstellt.

```
public void requestMove(){
	//start maximizing minMaxTask for every possible move
	List<Move> moves =
		Move.getPossibleMoves(manager.playerColor, gmlc.getPlayfield());
	[…]
```

Danach wird ein erster wichtiger Optimierungsschritt durchgeführt. Wenn nur ein Zug verfügbar ist, was oft passiert durch die Schlagzwang Regel [Regeln im Anhang], wird keine weitere Berechnung gestartet. Es gibt schließlich nur diesen einen Zug der ausgewählt werden kann.

```
	[…]
	if(moves.length == 1) {
		moves.toFirst();
		gmlc.makeMove(moves.get());
		return;
	}
	[…]
```

Wenn das nicht der Fall ist wird als nächstes der MiniMax Suchbaum aufgebaut und der Wert eines jeden Kindknotens evaluiert. Wenn der Wert besser ist als der Vorherige wird der momentane Wert der neue höchste Wert und der Zug der von diesem Knoten bewertet wurde der neue beste Zug. Am Ende der Methode wird dann der beste Zug ausgeführt.

```
	[…]
	float v;
	for(moves.toFirst(); moves.hasAccess(); moves.next()){
		v = new MiniMaxTask(
			tmpman,
			moves.get(),
			gmlc.getPlayfield().copy(),
			1,
			//the next task is always not maximizing
			false
			).compute();
		if(v > bestValue){
			bestValue = v;
			bestMove = moves.get();
		}
	}
	gmlc.makeMove(bestMove);
}
```

Der eigentliche MiniMax Such-/ und Auswahlprozess findet in der compute() Methode statt. Dort wird zunächst der zu bewertende Zug auf dem Spielfeld ausgeführt.

```
public float compute() {
		pf.executeMove(move);
	[…]
```

Daraufhin wird getestet, ob die maximale Tiefe erreicht ist. Wenn dies der Fall ist, wurde das Ende des Suchbaums erreicht und es kann das Ergebnis der Bewertung zurückgegeben werden.

```
[…]
if(depth >= manager.maxDepth){
	return evaluateMove();
}
[…]
```

Im MinMaxTask unterscheidet sich die Auswahl der Bewertungen insofern, dass hier nicht immer der beste Wert genommen wird sondern, wenn der Task nicht maximiert (also isMaximizing falsch ist), die minimalste Bewertung ausgewählt.

```
[…]
if(isMaximizing ? v > value : v < value){
	value = v;
}
[…]
```

Die oben genannte Bewertungsfunktion ist in der Methode evaluateMove() implementiert. Hier wird der Manager genutzt, um die ursprünglichen Figurenanzahlen zu erhalten.

```
private float evaluateMove() {
	return (manager.getFigureQuantity(manager.enemyColor)-
		pf.getFigureQuantity(manager.enemyColor))+
		(pf.getFigureQuantity(manager.playerColor)-
		manager.getFigureQuantity(manager.playerColor));
}
```

3.2 Variationen

3.2.1 Alpha-Beta Suche

Die Alpha-Beta Suche ist eine effizientere Alternative zur normalen kompletten Durchsuchung des aufgebauten Baums. Mit dieser Art der Suche können manche Teile des Baums ignoriert werden, da die sowieso nicht an den minimale Wert(alpha) und maximalen Wert(beta) gelagen können und somit keine Bedeutung mehr haben.
Diesen Vorgang nennt man Alpha oder Beta Schnitt. Die Anzahl der zu bewertenden Situationen sinkt also je mehr Schnitte gemacht werden. Insgesamt man der Algrithmus durchschnittlich 8421 Betaschnitte und 3101 Alphaschnitte pro Spiel. Dadurch kann die Rechenzeit drastisch verbessert werden.
Wie in unserer Implementierung für einen beta-Schnitt zu sehen ist, wird hier ein ganzer Zweig nicht mehr berücksichtigt, weil unter bestimmten Bedingungen schon abgebrochen wird. Dies geschieht wenn der aktuelle Wert größer ist als der Wert von beta, welcher aus einer höheren Tiefe übergeben wurde, da so gar nicht die Chance besteht dass, dieser Zweig überhaupt genommen wird.

```
[…]
if(isMaximizing && v > value){
	value = v;
	if(v >= beta) {
		return value;
	}
	alpha = v;
}
[…]
```

3.2.2 Multithreading

Die Multithreading-Version des MiniMax gleicht in der grundlegenden Arbeitsweise dem „normalen“ MiniMax. Es wurde nur eine für Multithreading optimierte Implementierung genutzt. Hier wird jeder MiniMaxTask als eigene Aufgabe an einen Ausführungsservice abgegeben und parallel ausgeführt. Am Ende seiner Ausführung ruft jeder Task eine Callback Funktion seines Elternknotens auf mit der er das Ergebnis übergibt. Als Ausführungsservice wird ein von uns selbst programmierter StackExecutor verwendet.

3.3 Effizienzvergleich

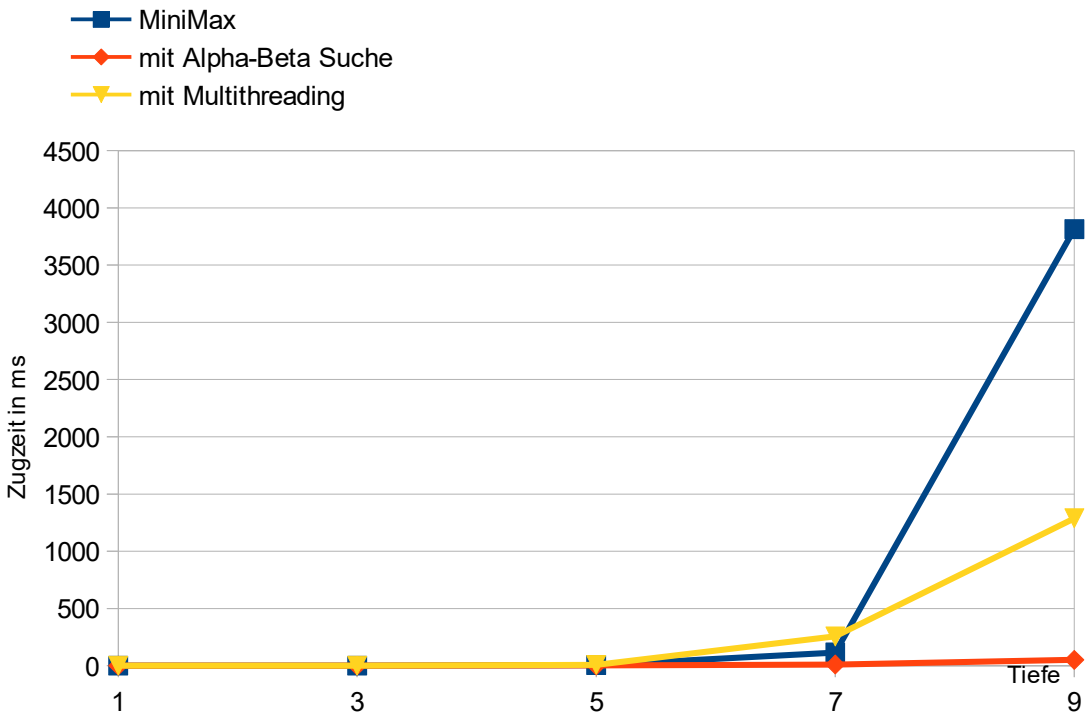

Abbildung 3.4: Durchschnittliche Zugzeiten aller MiniMax Varianten in verschiedenen Tiefen in Millisekunden.

Im direkten Vergleich zeigt sich, dass die Alpha-Beta Suche eine enorme Beschleunigung ermöglicht. Bei Tiefe 9 ist der MiniMax mit Alpha-Beta Suche etwa 75-mal so schnell wie der ohne Modifizierung und immer noch 25 mal so schnell wie die Variante mit Multithreading. Die Prozessorauslastung ist bei Alpha-Beta und „normalem“ MiniMax gleich. Sie liegt bei etwa $1/Anzahl\ der\ Prozessorthreads$. Der Multithreading MiniMax verbraucht allerdings immer nahezu 100 Prozent der Prozessorleistung. Beim Verbrauch anderer Ressourcen wie Speicherplatz sind alle Varianten gleichauf. Jede Einzelne verbraucht als .jar Datei etwa 6 Kilobytes[10].

3.4 Zusammenfassung

Zusammenfassend kann gesagt werden, dass der Mini-Max ein guter Lösungsweg ist, der die Berechnungen direkt im Spiel durchführt und sich somit als praktisch erweist. Zu dem kann er mit verschieden Varianten noch effizienter und schneller arbeiten. Am besten wäre es natürlich Alpha-Beta und Multithreading zu verbinden, jedoch birgt das einige Probleme, da die Alpha-Beta Such sich nicht so einfach parallelisieren lässt. Die Implementierung ist nur 150 Zeilen lang und somit überschaubar. Man kann als Nachteil betrachten, dass die Ergebnissse nie gespeichert werden. Das ist zum einen nicht effizient und zum anderen ist es dadurch schwer ein ganzes Spiel auf einer sehr hohen Spielstärke zu spielen (hohe Tiefe), da die Rechenleistung dafür einfach unglaublich hoch sein muss, wenn jeder Zug neu berechnet werden muss. Bei schwachen CPUs kann es auch durchaus sein, dass er schon bei relativ geringer Tiefe sehr lange für einzelne Züge braucht.

10 Von Windows auf einem NTFS Dateisystem berechnet.

4. Das Neuronale Netzwerk

4.1 Einführung

Der Mensch ist immer noch einer der besten Dame-Spieler in unserer Auswahl. Auch wenn er vielleicht nicht immer ein perfektes Spiel wie ein MiniMax mit hoher Tiefe spielt, kann er mit ein wenig Übung innerhalb von Sekunden relativ zuverlässig eine gute Entscheidung treffen und so selbst gegen den perfekt-spielenden Gegner noch einen Gleichstand erspielen. Diese Fähigkeiten sind in der Komplexität unseres Gehirns begründet. Es besteht aus Milliarden von Neuronen die alle parallel laufen, ununterbrochen unsere Sinneseindrücke verarbeiten und in Wissen oder konkrete Aktionen umwandeln.
Um diese Vielseitigkeit auch in der Informatik nutzen zu können, muss ein „Modell“ des Gehirns implementiert werden.
Mit anderen Worten ein künstliches neuronales Netz.
Ein neuronales Netzwerk beschreibt in der Informatik eine Struktur, die viele einzelne künstliche Neuronen mit teilweise unterschiedlichen Fähigkeiten in einer geschichteten Struktur verbindet in die „vorne“ eine Eingabe gegeben wird und die dann hinten eine Ausgabe basierend auf diesen Eingaben gibt. Die einzelnen Neuronen sind stark einer menschlichen Nervenzelle nachempfunden[10]. Ein Neuron hat einen oder mehrere Inputs und einen Output(der allerdings zu mehreren anderen Neuronen führen kann). Meistens wird der Output berechnet indem alle Inputs summiert und dann durch eine Funktion verändert werden. Die Neuronen sind allerdings nicht direkt miteinander verbunden, sondern kommunizieren über eine Verbindung. Diese Verbindung hat ein Gewicht, welches mit dem ankommenden Wert multipliziert und dann erst weitergegeben wird.

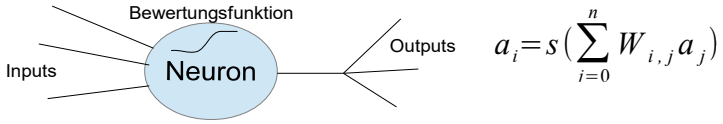

Abbildung 4.1: Modell eines Neurons und die Berechnungsfunktion für den Output

In dieser Formel wird der Outputwert als a von i, die Funktion als s(x), die Gewichte der Verbindungen als W und die Ausgabe der Zellen der vorherigen Schicht als a von j beschrieben. Beispiele für die sogenannte Aktivierungsfunktion sind

die Sigmoidfunktion $s(x) = 1/(1+e^{-x})$,

eine binäre Schwellwertfunktion mit Schwellwert t $\begin{matrix} x < t \Rightarrow s_1 \\ x \geq t \Rightarrow s_2 \end{matrix}$,

oder eine lineare Funktion $s(x) = m * x + b$.

In einem NN befinden sich also eine große Zahl von Parametern die verändert werden können. Dadurch wird ein hoher Grad an Universalität erreicht, da theoretisch jede Art von Information bei gleicher Struktur verarbeitet werden kann. Neuronale Netze sind also vereinfachte Modelle des Gehirns und sind deshalb sehr vielseitig einsetzbar und können viele unterschiedliche Aufgaben erledigen. Ein gutes Beispiel dafür, dass künstliche neuronale Netze auch komplexe Aufgaben wie das Spielen von Brettspielen erledigen können, ist das von Google DeepMind entwickelte AlphaGo.

4.2 Umsetzung

Deep Feed Forward (DFF)

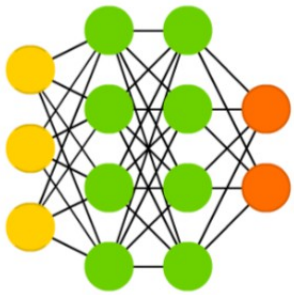

Bei unserem neuronalen Netzwerk haben wir uns für eine Deep Feed Forward Struktur entschieden, auf die später noch genauer eingegangen wird.
In nebenstehender Abbildung sind gut die vorher angesprochenen verschiedenen Arten von Neuronen zu sehen.
Das abgebildete neuronale Netz besteht aus Input-Neuronen, welche in der Abbildung gelb dargestellt werden, Hidden-Neuronen, welche in der Abbildung grün dargestellt werden, und Output-Neuronen, die orange dargestellt sind.

Abbildung 4.2: DFF Netzwerk

Ein Netz kann als deep bezeichnet werden, wenn es mehr als eine Schicht von Hidden-Neuronen besitzt.
Ein Neuronales Netz bekommt immer Zahlen als Input. Bei einem Feed Forward-Netz berechnet man den Output indem erst die Input-Neuronen auf die Werte des Inputvektors gesetzt und dann die Layer und die Verbindungen nacheinander aktualisiert werden. Hierbei geben die Input-Neuronen den ihnen zugewiesenen Wert nur an die Verbindungen weiter. Die Verbindungen wiederum multiplizieren den Wert mit ihrem Gewicht und geben das entstandene Produkt dann an die Hiddenneuronen des ersten Hidden-Layers weiter. Wenn ein Hiddenneuron mehrere Werte von den Verbindungen bekommen hat und aktualisiert wird, addiert es diese Werte erst zu einer Summe, welche dann eine Aktivierungsfunktion, die auch Transferfunktion genannt wird, durchläuft.
Wir benutzen für unser Projekt nur die Sigmoidfunktion[11]. Nachdem alle Neuronen, eines Hidden-Layers, geupdatet wurden geben alle ihre berechneten Werte an die Verbindungen weiter, welche diese wieder mit einer Variable multiplizieren und weitergeben. Dieser Vorgang wird solange wiederholt bis die Werte schließlich an den Output-Layer weitergegeben werden. Die Output-Neuronen funktionieren wie die Hidden-Neuronen bis auf den Unterschied, dass sie den Wert nicht mehr weitergeben. Nachdem diese aktualisiert wurden, bilden ihre Werte den Output des Netzes.
Das neuronale Netz besteht aus einer einzelnen Klasse. In ihr befinden sich die Variablen, die die Gewichte, der Verbindungen und den Bereich, indem die Sigmoidfunktion skaliert wird angeben. Die folgende Tabelle zeigt die Methoden der Klasse NN und beschreibt diese.

Methode	**Beschreibung**
`randomWeights()`	Allen Gewichten wird ein zufälliger Wert in einem festgelegten Bereich zugeordnet.
`vector_matrix_multiplication()`	Die Übergabe, Multiplikation mit den Gewichten und die Addition der Werte, der Neuronen, einer Schicht, haben wir hier durch eine Matrizenmultiplikation, bei der die Werte, der Neuronen einen Vektor und die Gewichte eine Matrix bilden, umgesetzt.
`sigmoid()`	Ein übergebener Wert wird in eine gestauchte und verschobene Sigmoidfunktion eingesetzt und das Ergebnis wird zurückgegeben.
`changeAll()`	Alle Gewichte werden mit zufälligen Werten, in einem festgelegten Bereich, multipliziert.
`changeFunction()`	Ein übergebener Wert wird in eine kubische Funktion, die für changeAll() gebraucht wird um die Zufallszahl, die für die Veränderung der Gewichte benötigt wird, zu skalieren, eingesetzt und das Ergebnis wird zurückgegeben.
`childFrom()`	Die Gewichte des neuronalen Netzes werden zu einer Mischung der Gewichte von zwei anderen Netzen geändert. Hierbei wird bei jedem Layer zufällig entschieden, von welchem Netz der Layer übernommen wird.
`run()`	Run nimmt als Parameter einen Inputvektor und gibt den Outputvektor zurück. Es wird also einfach das Netz

Abbildung 4.3: Methoden der Klasse NN

11 Die Funktion wird allerdings, je nach Einstellung, skaliert und verschoben um bei uns Werte von -1 bis 1 statt 0-1 zu erreichen.

Um uns das speichern und Übergeben der Struktur und Variablen, die das neuronale Netz bei der Initialisierung benötigt, zu vereinfachen, haben wir die Klasse NNSpecification geschrieben, in der diese Werte gespeichert sind. Unsere neuronalen Netze besitzen 64 Inputneuronen, 640 Hiddenneuronen, welche gleichmäßig auf 10 Layer aufgeteilt sind und 64 Outputneuronen. Damit besitzen sie 40960 Verbindungen, mit jeweils einem Gewicht.
Um ein neuronales Netz mit dem Brettspiel Dame zu verbinden haben wir die Klasse NNPlayer hinzugefügt. Diese hat erstens die Aufgabe das Feld der aktuellen Spielsituation an das neuronale Netz, das am Zug ist, weiterzugeben, wobei die ersten 32 Werte beschreiben auf welchen Feldern sich normale Figuren befinden und welche davon eine eigene und welche eine gegnerische ist. Hierbei steht eine 1 für eine eigene normale Figur, eine -1 für eine gegnerische normale Figur und eine 0 für ein leeres Feld oder eine Dame. Die zweiten 32 Werte beschreiben auf welchen Felder sich Damen befinden und welche davon eine eigene und welche eine gegnerische ist, hierbei steht eine 1 für eine eigene Dame, eine -1 für eine gegnerische Dame und eine 0 für ein leeres Feld oder eine normale Figur. Die zweite Aufgabe ist es basierend auf den Outputwerten einen Zug zu ermitteln, wobei von den ersten 32 Werten der höchste Wert das Feld angibt, zudem sich die Figur bewegen soll und von den zweiten 32 Werten der höchste Wert die Figur angibt, die sich dorthin bewegen soll, wobei nur Figuren berücksichtigt werden, für die dieser Zug möglich wäre. In einer Version des Netzwerks wird der Output auch so weiterverarbeitet, dass keine falschen Züge mehr gemacht werden können. Hierfür wird nicht der höchste Wert aus dem Output genommen, sondern der höchste Wert, mit dessen Feld gleichzeitig auch ein valider Zug möglich ist. Es wird also der Zug gewählt, der am Nächsten an der Entscheidung des NNs liegt.
Für die Umsetzung des Trainings des neuronalen Netzes haben wir die Klasse TrainingSession programmiert. Die folgende Tabelle zeigt die wichtigsten Methoden der Klasse TrainingSession und beschreibt diese.

Methode	**Beschreibung**
`train()`	Diese Methode startet das Training
`sortAndCalculateSum()`	Die Netze werden nach ihrer Bewertung sortiert und die beste und die durchschnittliche Bewertung wird ausgegeben.
`weightedRandomSelection()`	Ein zufälliges Netz wird zurückgegeben, allerdings ist es wahrscheinlicher, dass ein Netz mit besserer Bewertung zurückgegeben wird.
`randomizeArray()`	Die Netze werden zufällig angeordnet.
`isRunning()`	Testet ob trainiert wird.
`resetPlayer()`	Setzt die Fitnesswerte aller NNs zurück

4.3 Lernprozess/Optimierung

Das Neurale Netzwerk ist zu Beginn im ungelernten Zustand und somit noch nicht in der Lage das Problem ansatzweise zu lösen. Es muss, wie ein Mensch, erst einmal trainiert werden. Das Trainieren erfolgt durch die Veränderung der Gewichte, sodass für einen Input der richtige Output ausgegeben wird. Dazu gibt es mehrere Lösungsansätze, die wir ausprobiert und daraufhin miteinander verglichen haben.

3.2.1 Evolutionärer Ansatz
Zunächst haben wir uns für den evolutionären Ansatz entschieden, eine sogenannte supervised Lernmethode, die dem neuronalen Netz eine Belohnung für eine bessere Spielstärke gibt. Die Evolution wird hierbei als Vorbild genommen, denn man lässt die Netze gegeneinander oder gegen den MiniMax-Algorithmus spielen und bewertet dann welche am besten gespielt haben. Diese werden dann unverändert in die nächste Epoche übernommen. Die schlechteren werden aussortiert und durch sogenannte Mutationen der besten Netze ersetzt. Diese Mutationen sind eher kleine Veränderungen in den einzelnen Layern.
Auf diese Weise bleibt die Spielstärke der Netzte erhalten und es gibt die Chance auf eine positive Verbesserung.

3.2.1.1 Gegen sich selber
Am Anfang haben wir einen Output-Interpreter verwendet, welcher auch falsche Züge ermöglicht hat. Dadurch mussten wir die Bewertung zunächst sehr simpel halten, um auch kleinere Fortschritte zu bewerten.

Bedingung	Punkte
Richtiger Zug	+100
Falscher Zug	-100
Richtiger Schlag	+125

Abbildung 4.3: Fitnesspunkte für bestimmte Aktionen

Hier haben wir nach einiger Zeit festgesellt, dass die Anzahl der richtigen Züge durchaus steigt (ca. 4-5 Züge hintereinander), jedoch nur sehr langsam. Dies liegt auch daran, dass wenn richtige Züge im späteren Spielverlauf auftreten, diese nicht positiv gewertet werden können, da das Spiel vorher abbricht, weil schon relativ früh ein falscher Zug gemacht wird.

Bei dem Output-Interpreter, der nur richtige Züge macht, wird ein anderes Bewertungssystem benutzt. Bei diesem wird die Differenz der eigenen und der gegnerischen Figuren am Ende eines Spiels als Fitness genommen und zusammenaddiert. Dadurch entsteht eine gute Vergleichsbasis der Spielstärke. Je größer die Population ist, desto genauer lässt sich die Spielstärke feststellten, denn die neuronalen Netze sind ja einem zufälligen Spieler sehr ähnlich und können so mehr Spielfeld Situtationen abdecken.
Insgesamt haben wir durch diese Trainingsmethode einen sehr guten Erfolg feststellen können. Diesen haben wird ermittelt, indem wir das neuronale Netz, welches eine Hiddenlayer besitzt, gegen einen zufälligen Spieler 10.000-mal spielen lassen haben. Bei einer Population von 200 und über 200 Epochen sind die folgende Ergebnisse zustande gekommen: (5291-mal NN, 3248-mal Zufall und 1461 Unendschieden)
Jedoch lässt sich nach einiger Zeit keine signifikanten Verbesserung zu erkennen. Dies schließen wir auf die fehlende Komplexität des Netztes zurück, doch wenn man ein tieferes Netz nimmt, sind die Verbesserungen langsamer, da mehr Gewichte verändert werden können und somit die Chance geringer ist einen bestimmten Output zu erreichen.
Dieses Problem könnte mit einer anderen Netzstruktur gelöst werden. Die sogenannte Augmented Topology Struktur verändert während der Mutation auch die Struktur des NNs, sodass mit der Zeit erst komplexere Strukturen entstehen können.

3.2.1.2 Gegen MiniMax-Algorithmus
Da der MiniMax-Algorithmus deterministisch ist, gibt er bei einer bestimmten Situation immer den gleichen Zug aus. Dadurch ist es für das Neuronale Netzwerk relativ einfach diesen zu besiegen. Dies passiert so ungefähr nach 20 Minuten. Man benutzt auch hier als Bewertung die Differenz der eigenen und der generischen Figuren am Ende eines Spiels.
Trotzdem ist die Spielstärke relativ gering, da es sich nur auf eine bestimmtes Spiel spezialisiert und nicht für andere Spiele trainiert ist.

3.2.2 Backpropagation

Der Backpropagation Algorithmus funktioniert grundlegend anders als der evolutionäre Ansatz, da hier der jeweilige Output schon vorgegeben ist, den das NN für einen bestimmten Input annehmen soll. Diese ganzen Werte werden dann in einem Trainings Set gespeichert, welches je nach Größe 1 – 5 Millionen Spielzüge beinhaltet.
Grundsätzlich wird zunächst ein bestimmter Input der Trainingsdaten durch das Netz propagiert und der resultierende Output o mit dem gewünschten Output t verglichen. Daraus wird dann der quadratische Fehler mithilfe der Formel für alle Input und Output Paare berechnet: $E = \sum_{i=1}^{n} (t_i - o_i)^2$

Hier wird der Fehler für das Validation Set berechnet, welches ein Set ist, das nur Züge beinhaltet, die nicht im Trainings Set vorkommen. Dadurch wird geschaut, ob das NN die Lernfortschritte auch abstrahiert anwenden kann.

```
[…]
for(validationSet.toFirst(); validationSet.hasAccess();
validationSet.nextNoWrap()) {
	double[] output = nn.run(validationSet.get().input);
	for(int i = 0; i < output.length; i++) {
		error += Math.pow(validationSet.get().output[i] - output[i], 2);
	}
}
[…]
```

Durch viel Lernen wird dieser Fehler minimiert, wodurch man sagen kann, dass ein Lernfortschritt vorhanden ist.

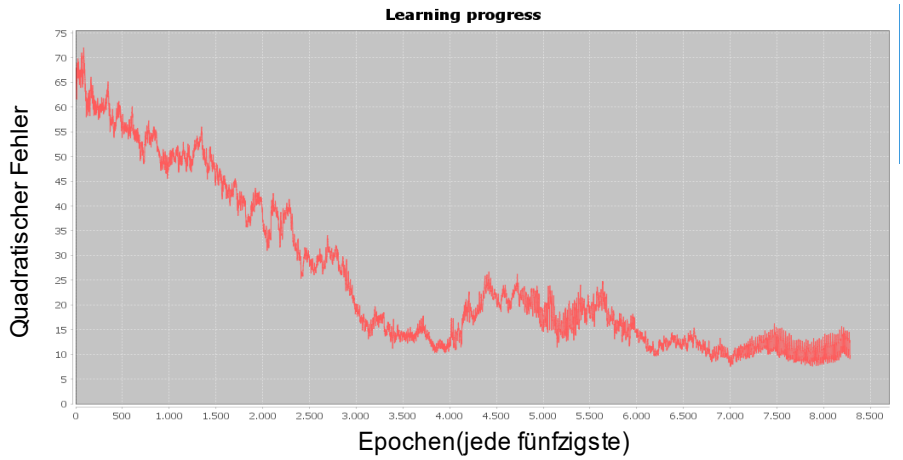

Um diesen Fehler überhaupt minimieren zu können, wird dieser mit dem Gradientenverfahren rückverfolgt und bestimmte Änderungen werden gemacht. Diese Änderungen lassen sich mit Hilfe der Abgeleiteten Fehlerfunktion berechnen: $\Delta w_{ij} = -\mu \delta_j o_i$
Die Ausgabe dieser Funktion beschreibt die Änderung des Gewichts zwischen dem Input des Neurons und dem Neuron. Für die Deltas, welche das Fehlersignal darstellen, werden je nach Verbindung unterschiedlich berechnet. Um das zu erreichen muss die Aktivierungsfunktion abgeleitet werden. In der Implementierung haben wir die Ableitung der Sigmoid Funktion dann folgendermaßen umgesetzt.

```
[…]
public double activation(double z) {
	return sigscale/( 1 + StrictMath.pow(Math.E,-z)) + sigoffset;
}
public double activationDev(double z) {
	return ((1 - activation(z)) * (activation(z) + 1))/2;
}
[…]
```

5. Andere Lösungsansätze

5.1 Datenbank als Lösungsansatz

Mit sehr hoher Rechenleistung ist es möglich das Spiel komplett zu berechnen, also jede einzelne Spielsituation mit dem besten Zug in eine Datenbank zu speichern. Mit dieser vollständigen Datenbank könnte man also theoretisch ein Spiel ohne Fehler spielen. Er wäre daher also unschlagbar.
Um das zu erreichen muss man einen kompletten Spielbaum erstellen. Jedoch steigt mit der Tiefe, wie schon beim MiniMax gezeigt, der Aufwand nahezu exponentiell.
Um in dieser Datenbank auf die einzelnen Daten, also die Züge zugreifen zu können, bräuchte man einen Primärschlüssel, der in jedem Datensatz einzigartig ist. Als diesen Schlüssel könnte man die Repräsentation des Spielfelds verwenden, da jeder Spielfeldsituation ein eindeutiger bester Zug zugewiesen werden kann.
Ein Spielfeld kann minimal in $3 * 32 = 96$ Bits gespeichert werden. Es sind nämlich nur 32 der 64 Felder des Bretts wirklich bespielbar. Daher können rote und weiße Figuren in jeweils 32 Bits gespeichert werden. Welche Figuren Damen sind könnte man auch in 24 Bits speichern, das wäre dann aber schwieriger zu benutzen.
Für eine Datenbank mit den perfekten Zügen müsste man für jede Spielfeldsituation höchstens 2 Züge (perfekter Zug für rot und schwarz) speichern. Es müssten aber keine Züge gespeichert werden, wenn nach den Regeln nur ein Zug erlaubt ist.
Ein Zug kann mit jeweils 5 Bits für Start- und Zielpunkt, einem Bit das zeigt ob der Zug auch ein Schlag ist und, wenn es ein Schlag ist, noch 32 Bit für alle geschlagenen Figuren gespeichert werden.
Die maximale Größe eines Datenpakets für eine Spielfeldsituation wäre also $96+2*43=182\,Bits$.

Insgesamt kann gesagt werden, dass diese Lösungsmöglichkeit mit Abstand die beste Spielstärke hätte. Dies geht aber vor Allem auf Kosten des Speicher- und Implementationsaufwands. Außerdem müsste eine passende Datenbank erstellt werden.

5.2 Zufallsbasierter Algorithmus

Dieser Algorithmus, welchen wir als erstes zu Testzwecken implementierten, wählt durchgängig nur zufällige, aber mögliche Züge aus. Die Auswahl an richtigen Zügen erhält dieser Algorithmus aus unserem Programm Checker Simulation 2.0, welches, wie schon bereits erklärt, das Spielfeld nach allen möglichen Zügen durchsucht. Er ist in der Spielstärke oft sehr schwach, kann jedoch als ein Lösungsweg betrachtet werden, da er einen vollwertigen Gegenspieler darstellt. Es besteht natürlich auch die Möglichkeit, dass er ein perfektes Spiel spielt jedoch ist dies Chance praktisch gleich null.
Insgesamt ist dieser Algorithmus von der Spielstärke her sehr schwach, hat jedoch den Vorteil, dass sowohl der Rechenaufwand als auch der Implementationsaufwand minimal ist.

6. Vergleich/ Fazit

Nachdem wir die einzelnen Ansätze im Detail ausgearbeitet haben, folgt nun der Vergleich dieser bereits analysierten Aspekte.
Besonders die Spielstärke spielt eine wichtige Rolle, da diese deutlich macht, wie gut das Problem gelöst wurde. Wir haben sowohl beim MiniMax Algorithmus als auch beim Neuronalen Netz feststellen können, dass der Rechenaufwand mit der Spielstärke zusammenhängt. Jedoch lässt sich ein zentraler Unterschied bei dem Zeitpunkt und der Art der Rechenaufwands feststellen. Beim MiniMax entsteht dieser vor jedem Spielzug, dadurch gibt es eine Verzögerung während des Spiels. Es wird somit nach jedem Zug nur ein Teil des ganzen Problems gelöst. Beim Neuronalen Netzwerk entsteht der Rechenaufwand durch das Lernen des Netzes. Dabei entsteht aber keine Verzögerung während des eigentlichen Spiels, sondern es muss vorher eine sehr große Anzahl an Spielen gespielt werden. Der Vorgang der Lösungsfindung findet also grundsätzlich über einen größeren Zeitraum statt. Die "Gewichte" der Neuronen werden aber immer gespeichert. Somit bleiben die gelernten Informationen erhalten und müssen nicht erneut berechnet werden. Im Verhältnis zum Minimax-Algorithmus ist dies sehr effizient, denn bei diesem werden keine Information über einen längeren Zeitraum gespeichert, sondern alles muss immer wieder neu berechnet werden. Es lässt sich aber trotzdem sagen, dass der zeitliche Aspekt abhängig von der Spielstärke und der Rechenleistung der Cpu ist. Das gilt grundsätzlich für jeden Ansatz. Ein extremes Beispiel dafür ist der Datenbank Ansatz.
Der Minimax kann direkt auf einem vorher definierten, bestimmten Niveau spielen, da die Spielstärke direkt durch die Tiefe angepasst wird. Beim NN kann die Spielstärke nicht direkt beeinflusst werden, da sie einfach nur langsam zunimmt. Der Ressourcenverbrauch ist beim Minimax am geringsten, gefolgt von dem Neuronalen Netz, welches etwas mehr Speicher für die vielen Netze, die beim Training erzeugt werden, benötigt. Beides ist aber sehr gering im Vergleich zum Datenbank Ansatz, bei welchem die ganze Situation gespeichert werden müssen.
Die konkrete Spielstärke des MiniMax ist schon bei relativ geringer Tiefe (5 – 10) ziemlich stark. Er gewann in 10000 Spielen 9736-mal (97,36%) mit 197 Gleichständen und nur 67 Verlusten. Da das NN ohne Nachbearbeitung der Ausgabe zuerst alle Regeln lernen muss, hat es eine sehr niedrige Spielstärke. Oft spielt es nur 3 – 7 Züge und macht dann einen Fehler, wodurch es disqualifiziert wird. Die andere Variante des NNs kann keine falschen Züge machen und ist deshalb untrainiert dem Zufallsspieler ähnlich. Allerdings verbesserte diese sich und war im Training so weit, den MiniMax zu schlagen. Allerdings muss man hierbei auch bemerken, dass es höchstwahrscheinlich nur gegen den diesen spezifischen (zum Training benutzten) MiniMax bestehen kann, da es nur diesen Gegner kennt.
Alle Methoden sind relativ einfach zu implementieren, wenn man das grundlegende Prinzip verstanden hat und die Voraussetzung wie Rechenleistung, Zeit und Speicher besitzt. Beim Datenbank Ansatz hatten wir nicht alle Voraussetzungen und konnten ihn deshalb nicht implementieren. Wir haben aus eigener Erfahrung gesehen, dass das NN deutlich fehleranfälliger ist.
Zusammengefasst lässt sich sagen, dass alle Ansätze Stärken und Schwächen aufweisen aber trotzdem in der Lage sind das Problem gut zu lösen. Der MiniMax ist deutlich flexibler, kann direkt eingesetzt werden und hat, im Gegensatz zum NN, einen genau definierbaren Rechenaufwand für eine bestimmte Spielstärke. Bei einer hohen Spielstärke und einer schwachen CPU kann das Spielerlebnis durch die lange Berechnung aber negativ beeinflusst werden. Daher ist es sinnvoller in diesem Fall das NN zu verwenden. Dieses benötigt nur Zeit im Vorhinein, danach kann es ohne Einschränkungen auf fast jedem System verwendet werden.
Durch unsere Ergebnisse lassen sich allgemeine Unterschiede zwischen den Ansätzen feststellen, die auch auf andere Probleme abstrahiert werden können. Konventionelle Lösungsalgorithmen sind oft für simple klar definierbare Probleme die effizienteste Lösung wie auch beim Brettspiel Dame. Hingegen ist Maschinelles Lernen sinnvoll, wenn Dinge selbständig erlernt werden sollen, was bei dem Brettspiel auch vom Vorteil ist, da das Problem dann auf eine menschliche Weise gelöst werden kann und man vielleicht mehr das Gefühl hat gegen einen menschlichen Gegner zu spielen. Das NN hat ein besseres Verständnis von dem Problem und kann auch durch Mustererkennung ohne detaillierte Lösungsanweisungen oft komplizierte Probleme lösen, braucht aber viel Zeit für das Lernen. Dies haben wir bei unserem Projekt gut beobachten können. Wenn viele Daten vorhanden sind, kann mit einem Datenbankspieler oft ein nahezu perfektes Spiel erreicht werden.

Trotz der Schwächen sind wir insgesamt mit den Ergebnissen des Projektes zufrieden. Wir haben fundamentale Unterschiede zwischen den einzelnen Ansätzen herausfinden können, die wir zuvor in unserem Programm Checkers Simulation 2.0 selbständig implementiert haben. Zudem haben wir vieles in den Bereichen maschinelles Lernen, objektorientierte Programmierung, GUI Programmierung, Netzwerk Programmierung und wissenschaftliches Arbeiten dazugelernt.

7. Quellenverzeichnis

[1] https://www.focus.de/wissen/mensch/geschichte/erfindungen/tid-5356/rechenmaschine_aid_51261.html
[2] https://de.wikipedia.org/wiki/Pascaline
[3] https://de.wikipedia.org/wiki/Rechenmaschine#Historische_Entwicklung
[4] https://de.wikipedia.org/wiki/Blaise_Pascal
[5] https://de.wikipedia.org/wiki/Problem_des_Handlungsreisenden
[6] https://de.wikipedia.org/wiki/Floating_Point_Operations_Per_Second
[7] https://de.wikipedia.org/wiki/TOP500
[8] www.de.wikipedia.org/wiki/Minimax-Regel
[9] www.de.wikipedia.org/wiki/Minimax-Algorithmus
[10] https://de.wikipedia.org/wiki/Nervenzelle

Bedienungsanleitung:

Installation:
Es muss einfach nur die .jar-Datei ausgeführt werden. Um Fehler zu vermeiden sollte die neueste Java Version auf dem Computer installiert sein.

Optionen beim Start eines Spiels:
Wenn man auf Run>new Run klickt öffnet sich ein neues Fenster, in man einige verschieden Optionen auswählen kann:

- ***runName:*** Das Spiel wird benannt. Ist nur notwendig, wenn gameRecording aktiviert ist.
- ***gameRecording:*** Wenn man diese Option anklickt, werden im Ordner recources/recordedGame einige Informationen über diese Spiele gespeichert, die für die Auswertung genutzt werden können.
- ***Rounds:*** Setzt die Anzahl der Runden, die gespielt werden sollen.
- ***Spielerauswahl:*** Ein Dropdown-Menü, indem alle Spieler angezeigt werden, die sich im resources/AI Ordner befinden + einen 'Player', der für einen menschlichen Spieler steht.
- ***Display enabled:*** Wenn diese Option ausgeschaltet wird, wird das Spiel nicht angezeigt. (Kann nur deaktiviert werden, wenn beide Spieler Computerspieler sind!)
- ***using current playfield:*** Spiel wird mit dem aktuellen Spielfeld gestartet. (Kann nur aktiviert werden, wenn sich eine Situation auf dem Spielfeld befindet, die Bespielbar ist!)
- ***Schieberegler:*** Beeinflusst die Verzögerung, die Computergegner haben. (fast: 0sek, medium: 1sek, slow: 5sek)

Laden und Speichern von Spielsituationen:
Man kann Situationen auf dem Feld speichern, indem man Game>save situation benutzt. Eine Situation lässt sich aber nur mit Game>load situation laden, wenn gerade kein Spiel läuft. Dazu muss man im Auswahlfenster die gewünschte .pfs Datei auswählen. Man kann dann auch ein Spiel mit der geladen Ausgangssituation starten, indem man im Run>new Run Fenster useCurrentPf anklickt.

Während eines Spiels:
Das Spiel kann pausiert oder gestoppt werden unter run. Außerdem kann man unter preferences noch einige Optionen vom Start auch noch während einem Spiel verändern.

Wie man einen Spieler hinzufügen kann:
Wenn man einen Spieler selbstständig programmieren möchte, dann kann man diesen als .class oder .jar Datei in den resources/AI Ordner einfügen. Eine der Klassen des Computerspielers benötigt dazu das Interface 'Player'. Die Information über das Spielfeld können über die öffentlichen get Methoden des Programms erhalten werden.

NN Training:
Das NN Training Fenster kann geöffnet werden mit run>NN Training. Dort können die NN Einstellungen spezifisch angepasst werden und es kann ein Training gestartet und gestoppt werden. Die dabei entstandenen NN Dateien werden in dem Ordner resources/Trainingssessions gespeichert.
Um im Hauptprogramm gegen eines dieser trainierten NN's zu spielen, muss eine der .json Dateien, die ein NN repräsentieren, in den recources/NNPlayer1Info Ordner oder resources/NNPlayer2Info Ordner.

Weitere Funktionen:
Diese Funktionen haben keine große Relevanz für das Projekt, können aber trotzdem ganz nett sein. Beispielsweise kann bei preferences>Color die Farbe des Programmes und die Farbe der Schrift in der Konsole verändert werden.
Über die Console kann man darüber hinaus auch weitere Dinge mithilfe von Commands einstellen.
Außerdem hat das Programm Soundeffekte für das Spiel und einen Musicplayer. Diese können mit mit Preferences>Sound verändert werden. Lieder kann man im Ordner recources/Music einfügen.
Es gibt auch die Möglichkeit zwei Programme über ein lokales Netzwerk zu verbinden. So kann dann über die Konsole kommuniziert werden oder ein Spiel gestartet werden, bei dem die beiden gegeneinander spielen können.

Regeln Checkers

Die von uns genutzte Variante nennt sich Checkers(im Englischen) oder Draughts(im Amerikanischen) und wird vor in vielen englischsprachigen Ländern gespielt.
Ein 8×8 Spielfeld gespielt dient als Grundlage, wobei immer nur jedes zweite Feld bespielbar ist. Zu Beginn besitzt jeder Spieler 12 Figuren, die folgendermaßen auf dem Spielfeld angeordnet sind:

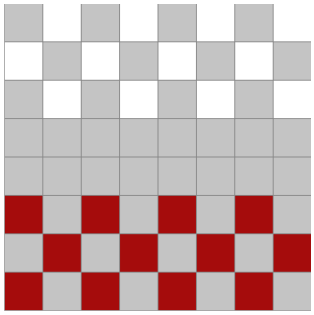

- Figuren können sich nur diagonal ein Feld vorwärtsbewegen oder eine Figur schlagen.
- Es kann nur geschlagen werden, wenn diagonal links oder rechts auf dem nächsten Feld ein gegnerische Figur steht und sich diagonal auf der Linie hinter dieser Figur eine freies Feld befindet.
- Das Schlagen ist zwingend. Wenn es eine Möglichkeit zu schlagen muss diese auch ergriffen werden.
- Wenn man einen Schlag vollführt, muss man direkt auf dem Feld hinter der geschlagenen Figur landen.
- Es ist auch möglich mit einer Figur mehrere Schläge in einem Zug auszuführen. Auch hier ist das Schlagen der nächsten Figur zwingen notwendig.

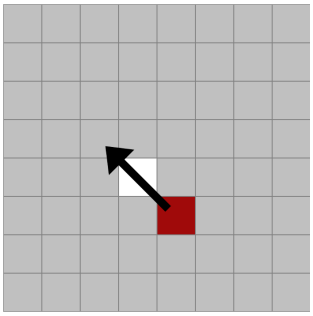

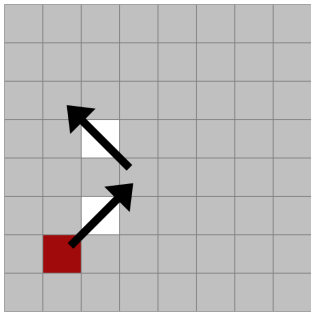

- Wenn eine Figur geschlagen wird, dann wir sie permanent vom Spielfeld entfernt.
- Wenn man mit einer Figur die andere Seite des Spielfelds erreicht hat, wird die Figur zu einer Dame. (in Checker Simulation 2.0 wird das durch eine Krone auf der Figur repräsentiert). Diese hat nun auch die Möglichkeit rückwärts zu gehen und rückwärts zu schlagen.
- Es fängt immer der Spieler mit den roten Figuren an.
- Das Ziel des Spiels ist entweder alle Figuren des Gegners vom Spielfeld zu entfernen oder die noch verbleibenden gegnerischen Figuren zugunfähig zu machen.
- Wenn 50 Züge hintereinander keine Figur mehr geschlagen wird, dann wir automatisch ein Unentschieden erzwungen. Beide Spieler können sich auch schon vorher auf ein Unentschieden einigen.